

Relatório Final

Desafio: Análise Avançada de Dados

Bárbara Ranielly Tavares Ferreira
Uninter
barbararanielly15@gmail.com

Resumo

Este trabalho apresenta o desenvolvimento de um pipeline preditivo e analítico ponta a ponta na plataforma Databricks, utilizando a arquitetura Medalhão, voltado à antecipação de alertas críticos do tipo "Don't Go" em frotas de mineração. O objetivo central consistiu em identificar quais equipamentos apresentam maior risco de parada nas horas subsequentes a partir de dados transacionais de telemetria e ciclos de operação. Na fase de entendimento dos dados (EDA), realizou-se uma varredura rigorosa que identificou nulos textuais disfarçados e anomalias críticas de instrumentação. O principal achado revelou que 70,5% dos alertas brutos de falha eram causados por *chattering* (oscilação espúria de sensores), concentrados expressivamente no ativo CA65926. Para mitigar esse ruído técnico que corromperia o aprendizado dos modelos, implementou-se um algoritmo de *debounce* temporal de 30 minutos na camada Silver, reduzindo os 19.962 eventos brutos para 5.890 episódios reais e independentes de risco. Adicionalmente, detectou-se um evento de inundação (*flood*) de ingestão no ativo PE3798 no dia 29/06/2025 (1,33 milhão de registros), tratado via Winsorização no percentil 99. Na modelagem, utilizou-se uma divisão temporal estrita (70% treino / 15% validação / 15% teste) para evitar vazamento de dados. Foram confrontadas duas abordagens na camada Gold: uma supervisionada (Random Forest) e outra não supervisionada (Isolation Forest). Visando a eficiência de negócio, priorizou-se a métrica de *Recall* sobre a *Precision*, dado que o custo de uma parada não planejada supera o de uma inspeção preventiva. Ao ajustar o ponto de operação na curva Precision-Recall, o modelo Random Forest atingiu um *Recall* de 70,0% para uma janela preditiva de 4 horas, superando o desempenho do baseline heurístico (55,4%) em +14,6 pontos percentuais. A análise de interpretabilidade via SHAP validou os critérios operacionais do modelo, enquanto a análise de erros por frota revelou desempenho desigual na frota minoritária Letourneau L-1850 (100% de falsos negativos devido à escassez de dados), direcionando os planos de ação futuros para modelos dedicados. Os resultados confirmam a viabilidade prática da solução para o monitoramento em tempo real do despacho.

Palavras-Chave: Engenharia de Dados; Telemetria; Mineração; Modelagem Preditiva; Databricks.

1. Introdução

No cenário contemporâneo da mineração de alta performance, a transição de uma manutenção puramente reativa para uma estratégia preditiva é fundamental para garantir a segurança das operações e a produtividade da lavra. A tomada de decisão

baseada em dados permite que falhas graves sejam antecipadas, evitando paradas não planejadas de equipamentos de grande porte, que geram altos custos de manutenção corretiva e ociosidade da frota. Os dados que viabilizam essa inteligência têm origem em sensores instalados nas máquinas (transações de telemetria) e nos registros de jornada de trabalho preenchidos pelos operadores (apontamentos operacionais).

O objetivo central deste trabalho é desenvolver um processo de ETL (Extração, Transformação e Carga) robusto e escalável utilizando a arquitetura Medalhão (Bronze, Silver e Gold) dentro do ambiente Databricks. A meta é aplicar regras de negócio complexas e saneamento de dados rigoroso sobre esses fluxos contínuos. Com isso, busca-se estruturar uma base histórica altamente confiável para treinar modelos preditivos de aprendizado de máquina, permitindo uma tomada de decisão ágil e preventiva por parte da equipe de despacho de mina.

2. Entendimento do Negócio

2.1 Contextualização da Operação de Mina

A operação de mina gera dois fluxos de dados principais que sustentam este trabalho:

- **Apontamentos:** Cada registro representa um ciclo de atividade de um equipamento, identificado por Tag, Frota e Tipo (como Caminhão ou Carregadeira), com horário de início e fim e a classe da atividade executada.
- **Telemetria:** Eventos de sensores por equipamento, incluindo o código do alarme disparado, o nível de criticidade técnica, o valor lido no instante e a flag `is_dont_go`, que sinaliza se aquele evento constitui um alerta impeditivo.

Um alerta do tipo "Don't Go" indica que o equipamento apresenta um risco iminente e não deve continuar operando, impactando diretamente a segurança do operador, a disponibilidade física da frota e as metas de produção de lavra. O catálogo de regras de negócio (Alarmes - SUL_SUDESTE.xlsx) define teoricamente as combinações de parâmetros que geram esse alerta. No entanto, identificou-se que o catálogo adota uma taxonomia e escala de criticidade incompatíveis com a base de telemetria. Por essa razão, este projeto adota a coluna nativa `is_dont_go` como a única e definitiva fonte de verdade (*Ground Truth*) para a identificação dos alertas críticos.

2.2 Definição do Problema Analítico

Para extrair valor desses dados, definiu-se a seguinte pergunta analítica orientadora:

"Quais equipamentos têm maior risco de gerar um alerta 'don't go' nas próximas horas, considerando o padrão atual de operação — e existe um sinal de comportamento anômalo que antecede esse alerta?"

Essa abordagem conecta duas frentes de modelagem:

1. **Supervisionada (Random Forest):** Estima a probabilidade de risco de falha em uma janela futura.
2. **Não Supervisionada (Isolation Forest):** Investiga a existência de comportamentos anômalos na telemetria que funcionem como sinais precursores da falha.

A métrica de sucesso de negócio priorizada é o **Recall** (percentual de alertas reais antecipados corretamente). No contexto de mina, o custo de um falso negativo (perder uma falha real e parar a produção) é drasticamente superior ao custo de um falso positivo (uma inspeção preventiva rápida agendada sem necessidade). O cenário de aplicação prática consiste em munir o sistema do *dispatcher* (despachador) com um painel de risco atualizado com **4 horas de antecedência**, viabilizando tempo hábil para a equipe de manutenção intervir antes da quebra.

3. Metodologia

A solução técnica foi implementada no Databricks utilizando PySpark e estruturada nas três divisões da arquitetura Medalhão:

3.1 Camada Bronze (Ingestão)

Armazenamento dos dados brutos exatamente no formato em que foram extraídos das fontes de origem (apontamentos, telemetria e o catálogo de regras em Excel).

3.2 Análise Exploratória (EDA) e Saneamento de Dados (Camada Silver)

Antes de qualquer modelagem, realizou-se uma varredura analítica sobre a base de Telemetria, que cobre o período de janeiro a junho de 2025 e soma 37.164.054 registros. Essa inspeção revelou as premissas e correções aplicadas no pipeline da camada Silver:

- **Tratamento de Nulos Ocultos:** O diagnóstico inicial de nulos usando `isNull()` retornou um resultado enganoso de zero registros em quase todas as colunas. Identificou-se que a coluna Classe e outras variáveis categóricas utilizavam a string literal "null" em vez de nulos reais. Criou-se uma função genérica de

varredura textual para mapear as variações ('null', 'none', 'n/a', vazio) e substituí-las pela categoria "não informado", preservando o histórico das linhas.

- **Tratamento da Coluna Valor:** Conversão de strings não numéricas e do literal "NULL" para nulo real antes do cast para double. Optou-se por não preencher as ausências com zero (pois zero é um valor físico de leitura de sensor para determinados alarmes) e criou-se a flag explicativa valor_ausente.
- **Inconsistências Temporais em Apontamentos:** Remoção de ciclos com datas impossíveis (Início > Fim ou duração nula). Ciclos sobrepostos no mesmo equipamento foram apenas sinalizados (flag_overlap_ciclo) para evitar remoções cegas de trocas legítimas de operador.
- **Padronização e Case-Sensitivity:** Aplicação de trim() e lower() nas variáveis categóricas, com exceção deliberada de chaves e identificadores como Tag e Matricula_Operador_Hash para evitar colisões e manter o sigilo da anonimização.
- **Incompatibilidade Telemetria × Catálogo de Regras:** Testou-se a hipótese de mapear as duas bases usando o texto do alarme e o nível de criticidade. O teste foi **rejeitado** por incompatibilidade estrutural. O catálogo usa severidade binária ("alto"/"muito alto"), enquanto a telemetria mapeia em três níveis ("informacional"/"não crítico"/"crítico"), e as sintaxes de texto divergem (ex: "low engine coolant level" vs. "engine coolant level - active"). Abandonou-se este join e estabeleceu-se a coluna is_dont_go como a única verdade de campo (Ground Truth).
- **Tratamento de Chattering (Debounce):** O diagnóstico bruto apontou o ativo CA65926 isolado como líder de falhas (~5.000 alertas). Ao investigar o caso, constatou-se que o alarme de temperatura do freio oscilava de status (active/inactive) dezenas de vezes por dia em frações de minutos, com uma mediana de intervalo de apenas 0,06 horas (3,6 minutos). Aplicou-se um algoritmo de *debounce* temporal: alertas do mesmo par tag + alarme em intervalos menores que 30 minutos foram consolidados em um único episódio. Isso revelou que 70,5% dos alarmes brutos de falha eram ruído de instrumentação, restando apenas 5.890 episódios reais e independentes.
- **Auditoria de Decisões:** Todas as transformações, volumetrias afetadas e justificativas foram salvas na tabela física delta de auditoria vale_silver.controle_alteracoes.

3.3 Engenharia de Atributos e Modelagem (Camada Gold)

Os dados consolidados foram convertidos em uma série temporal de menor granularidade, agregados por Equipamento (tag) + Hora. A partir disso, construiu-se a inteligência do pipeline:

- **Tratamento do Outlier de Ingestão (Flood):** A análise de volume diário revelou um pico isolado de 1,48 milhão de leituras em 29/06/2025, dominado em 90% pelo ativo PE3798 (1,33 milhão de registros). Como o dia não coincidiu com o pico real de alertas operacionais (30/06), confirmou-se um transbordo de rede. Para conter o impacto, aplicou-se Winsorização com teto no percentil 99 do conjunto de treino.
- **Histórico Recente e Codificação:** Utilizou-se Window Functions de 24 horas para gerar features de quantidade de episódios recentes. Variáveis de baixa cardinalidade (Frota, Tipo e Turno) foram codificadas por *frequency encoding*. A feature de sufixo de texto foi descartada devido à correlação e redundância de 100% com a coluna classe.
- **Target e Validação Temporal:** Baseado na mediana real de tempo entre episódios pós-debounce (1,84 horas), o alvo de risco foi construído para duas janelas futuras: 4 horas (principal) e 8 horas (sensibilidade). A divisão dos dados foi cronológica (70% treino / 15% validação / 15% teste) para simular o ambiente de produção e impedir vazamento de dados futuros.
- **Algoritmos Avaliados:** Treinou-se o classificador supervisionado *Random Forest* (200 estimadores, pesos balanceados) e o detector de anomalias não supervisionado *Isolation Forest*. O parâmetro de contaminação deste último foi ajustado na proporção real de horas de risco no treino (0,1342) para investigar se o score de anomalia funcionaria como sinal precursor de quebra.

4. Resultados e Discussões

Os modelos desenvolvidos na camada Gold foram submetidos a testes rigorosos no conjunto de validação. O foco principal foi avaliar a capacidade de antecipação do Random Forest (abordagem supervisionada) e a identificação de comportamentos precursores pelo Isolation Forest (abordagem não supervisionada).

4.1 Desempenho dos Modelos e Escolha do Ponto de Operação

Como o custo operacional de uma falha crítica não detectada (falso negativo) supera expressivamente o custo de uma inspeção visual preventiva agendada (falso positivo), a métrica **Recall** foi priorizada sobre a *Precision*.

Em vez de adotar o limiar de decisão padrão de 0,5 do *Random Forest*, utilizou-se a curva Precision-Recall para mapear o ponto de operação ideal, estabelecendo-se a meta de capturar no mínimo 70% dos episódios reais de risco.

A tabela a seguir apresenta a comparação de desempenho dos modelos frente ao baseline heurístico (que assume a repetição de falhas nas próximas horas caso o ativo tenha apresentado histórico nas últimas 24h):

Modelo	Precision	Recall	F1
Baseline (4h)	0,158	0,554	0,245
Random Forest (4h, limiar 0,5)	0,227	0,494	0,311
Random Forest (4h, limiar ajustado)	0,149	0,700	0,245
Baseline (8h)	0,245	0,514	0,331
Random Forest (8h, limiar 0,5)	0,285	0,473	0,356
Random Forest (8h, limiar ajustado)	0,212	0,701	0,325
Isolation Forest (top-10% anomaly score, 4h)	—	0,079	—

A análise dos resultados revela que o *Random Forest* com limiar ajustado superou significativamente o baseline na janela principal de 4 horas, elevando o **Recall para 70,0%** (um ganho de **+14,6 pontos percentuais**). Isso significa que, na prática, o despacho da mina conseguiria antecipar 7 em cada 10 quebras reais com até 4 horas de antecedência.

O *Isolation Forest* obteve um *Recall* isolado de apenas 7,9% no top 10% de scores de anomalia. Esse resultado confirma que dados de telemetria isolados e instantâneos não carregam sinais precursores autônomos suficientes para prever falhas graves, validando a necessidade de features históricas complexas consolidadas em episódios.

4.2 Análise de Erros e Concentração por Frota

A matriz de confusão do modelo para a janela de 4 horas com o limiar ajustado apresentou a seguinte distribuição:

- **Verdadeiros Negativos (VN): 10.021 | Falsos Positivos (FP): 4.594**
- **Falsos Negativos (FN): 343 | Verdadeiros Positivos (VP): 802**

	A ^B _C tag	1 ² ₃ qtd_positivos_reais	1 ² ₃ qtd_falsos_negativos	1.2 taxa_de_erro
1	CA65921	55	37	0.6727272727272727
2	PE3797	34	34	1
3	CA65935	81	33	0.4074074074074074
4	CA65909	36	29	0.8055555555555556
5	CA65926	97	29	0.29896907216494845
6	CA65922	43	27	0.627906976744186
7	CA65931	71	21	0.29577464788732394
8	CA65928	39	19	0.48717948717948717
9	CA65936	74	13	0.17567567567567569
10	CA5926	16	12	0.75
11	CA65789	12	12	1
12	CA65932	16	12	0.75
13	CA65915	16	11	0.6875
14	CA65790	25	10	0.4
15	CA65792	80	8	0.1

Figura 1 — Top 15 equipamentos com mais falsos negativos, em valor absoluto e por taxa de erro.

Aprofundando o diagnóstico de erros, a análise de falsos negativos por frota revelou o comportamento mais crítico e importante do modelo:

Falsos negativos por frota:

Table ▾ +				
	A ^B _C frota	1 ² ₃ qtd_positivos_reais	1 ² ₃ qtd_falsos_negativos	1.2 taxa_de_erro
1	letourneau I 18...	34	34	1
2	793-d 3s	36	29	0.8055555555555556
3	793-d 4s	284	111	0.3908450704225352
4	793-d 2s	128	33	0.2578125
5	793-d 5s	663	134	0.20211161387631976

Figura 2 — Falsos negativos por frota: taxa de erro variando de 20,2% a 100%.

O desempenho apresentou uma disparidade severa entre as frotas:

- A frota majoritária "**793-d 55**", que contava com o maior volume de exemplos de treino (663 positivos), obteve a menor taxa de erro do pipeline (**20,2%** de falsos negativos).
- Em contrapartida, a frota minoritária "**letourneau I-1850**" (apenas 150 registros brutos na telemetria) registrou **100% de falsos negativos** (nenhum dos 34 episódios reais foi identificado).

Essa discrepância evidencia que a taxa de acerto está diretamente associada ao volume amostral disponível para cada tipo de ativo no conjunto de treinamento, e não a uma limitação inerente ao algoritmo.




Figura 3 — Precision e Recall por semana no período de validação.

4.3 Interpretabilidade Global do Modelo (SHAP)

O comportamento interno do modelo de florestas aleatórias foi mapeado utilizando a técnica de valores SHAP (Shapley Additive exPlanations):




Figura 4 — SHAP summary plot para o Random Forest, janela de 4h.

As duas variáveis de maior impacto positivo na tomada de decisão coincidem perfeitamente com os critérios operacionais de mina:

1. qtd_episodios_ultimas_24h
2. qtd_criticos_hora

Ativos que apresentam episódios recorrentes no período recente ou uma alta contagem de sinais de criticidade instantânea têm sua probabilidade de risco severamente elevada pelo modelo.

Uma variável chamou a atenção por apresentar um comportamento contraintuitivo: a qtd_eventos_ultimas_24h. Valores baixos dessa variável empurram o modelo em direção ao risco alto, enquanto valores elevados reduzem a probabilidade de risco. Duas hipóteses explicam essa mecânica operacional:

- Após a winsorização, volumes altos de eventos brutos indicam apenas sensores normais altamente verbosos em rotina de produção.

- Operacionalmente, um ativo que dispara um pré-alerta de risco entra em regime de inspeção ou redução de carga de trabalho pelas equipes de monitoramento. Essa intervenção prévia silencia temporariamente as transmissões do sensor, gerando um histórico de poucos eventos imediatamente antes do alerta crítico.

5. Conclusão e Trabalhos Futuros

Este projeto comprovou a viabilidade prática da antecipação de alertas impeditivos do tipo "Don't Go" utilizando a arquitetura Medalhão e ferramentas de aprendizado de máquina no Databricks. O desenvolvimento do pipeline garantiu que decisões cruciais de saneamento — como o tratamento matemático de *chattering* de sensores e a Winsorização contra inundações de rede — blindassem os modelos contra a ingestão de ruídos físicos de instrumentação.

Retomando as perguntas norteadoras do negócio, as principais conclusões obtidas foram:

- **Risco e Previsibilidade:** É possível estimar com precisão o risco de parada dos ativos nas próximas horas. O modelo *Random Forest* calibrado com ponto de operação ajustado na janela de 4 horas entregou um ganho de **+14,6 pontos percentuais de Recall** em relação à heurística prática atual de mercado, mostrando-se uma ferramenta de alto valor para o planejamento do despacho de mina.
- **Ausência de Sinais Precursores na Telemetria Instantânea:** A hipótese de identificar um comportamento anômalo isolado antes da falha a partir de telemetria instantânea não se sustentou. O baixo desempenho do *Isolation Forest* (Recall de 7,9%) demonstrou que desvios em tempo real, sem o contexto de engenharia de recursos históricos (como o histórico de episódios acumulados), não carregam sinal precursor forte o suficiente para prever falhas graves de forma autônoma.

5.1 Limitações da Abordagem Atual

Identificaram-se as seguintes restrições técnicas no ciclo de desenvolvimento atual:

- **Sensibilidade ao Volume por Classe:** O desempenho preditivo do modelo mostrou-se altamente vulnerável à quantidade de dados históricos de cada

frota, resultando em uma taxa de erro de 100% (falsos negativos) na frota minoritária Letourneau L-1850.

- **Janela Histórica Curta:** A restrição da base de dados a um período contínuo de 6 meses limita o mapeamento de padrões sazonais de longo prazo nas frotas.
- **Variáveis de Comportamento Estáticas:** As métricas de comportamento utilizadas na detecção de anomalias limitaram-se a níveis e desvios pontuais na hora, não avaliando tendências e derivadas temporais analógicas.

5.2 Trabalhos Futuros Propostos

Como evolução direta deste trabalho para garantir escala e robustez, propõem-se as seguintes frentes:

1. **Modelos Dedicados e Técnicas de Reamostragem:** Desenvolvimento de classificadores específicos para a frota Letourneau L-1850 ou aplicação de técnicas de *oversampling* ponderado de classe por frota no conjunto de treinamento para compensar o desbalanceamento amostral.
2. **Novas Variáveis Físicas e de Negócio:** Integração de séries temporais de derivadas e tendências físicas de sensores analógicos (pressão e temperatura de operação), histórico de ordens de serviço de manutenção corretiva/preventiva e indicadores meteorológicos da mina.
3. **Mecanismo de Retraining Automático e Deploy:** Estruturação de um pipeline contínuo de avaliação de *data drift* e retreinamento automático do modelo a partir do armazenamento físico das previsões materializadas na tabela `vale_gold.predicoes_risco_dont_go`.

Referências e Recursos

- **Alarmes - SUL_SUDESTE.xlsx** — Catálogo de regras de negócio para alertas 'don't go'.
- **Dicionario_Dados.xlsx** — Descrição das features da tabela Apontamentos e Telemetria.
- **Notebooks do projeto:** Notebook-Vale-Silver.py, Notebook-Vale-EDA.py, Notebook-Vale-Gold.py.
- **SHAP Documentation** — shap.readthedocs.io.
- **Scikit-Learn Documentation** — scikit-learn.org.